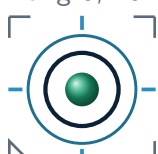
OmniGlass Edge

Trợ lý đa phương thức chạy hoàn toàn **on-device** cho người khiếm thị trên nền tảng Qualcomm Snapdragon (QCS8550)

Nhóm 2

Khoa Công nghệ Thông tin – Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM

Tháng 8, 2026



Nội dung

1. Động lực
2. Tổng quan hệ thống
3. Nhận thức luôn hoạt động
4. Nhận dạng giọng nói (STT)
5. Suy luận ngôn ngữ (VLM)
6. Tổng hợp giọng nói (TTS)
7. Lập lịch an toàn là ưu tiên số một
8. Demo trực tiếp
9. Tổng hợp benchmark
10. Nhật ký kỹ thuật
11. Hạn chế & hướng phát triển
12. Kết luận

Vì sao chọn on-device, không phải cloud?

Bài toán

Một trợ lý cảnh báo nguy hiểm cho người khiếm thị không thể chấp nhận độ trễ mạng, mất kết nối, hay để hình ảnh camera rời khỏi thiết bị.

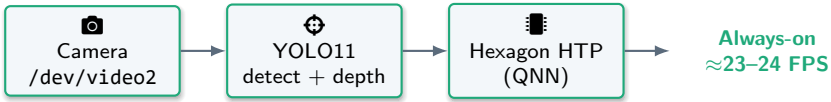
Trợ lý VLM trên cloud

- Độ trễ round-trip: hàng trăm ms tới vài giây
- Cần kết nối mạng liên tục
- Dữ liệu camera/mic phải rời khỏi thiết bị
- Chi phí tăng theo lượng sử dụng

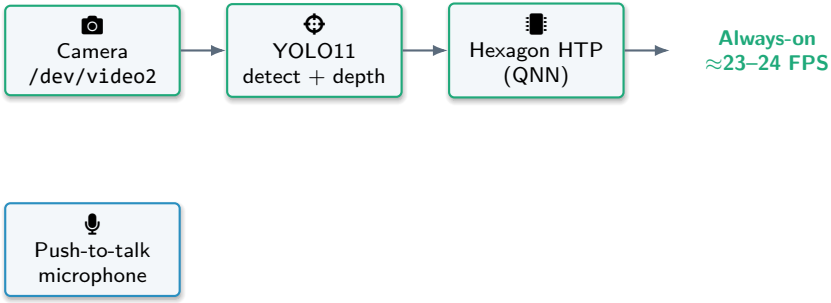
OmniGlass Edge

- Detection + depth chạy **cục bộ**, từng khung hình
- Hoạt động hoàn toàn offline
- Camera/mic không rời khỏi box
- Lập lịch có ý thức về nhiệt độ, an toàn là ưu tiên số một

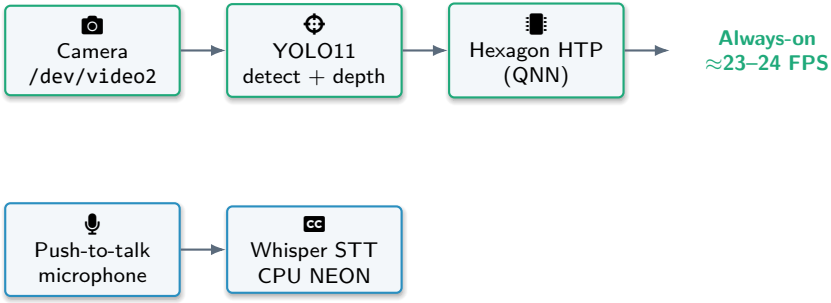
Pipeline đầu-cuối



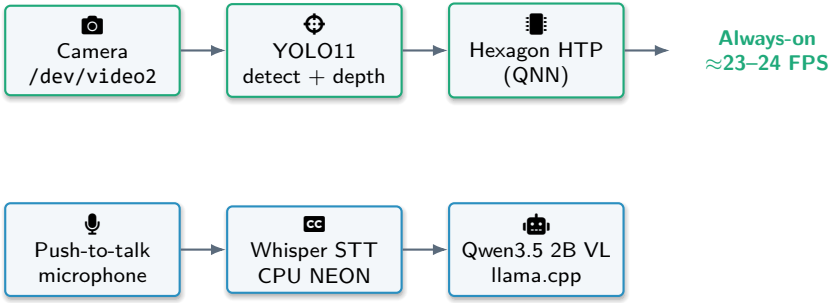
Pipeline đầu-cuối



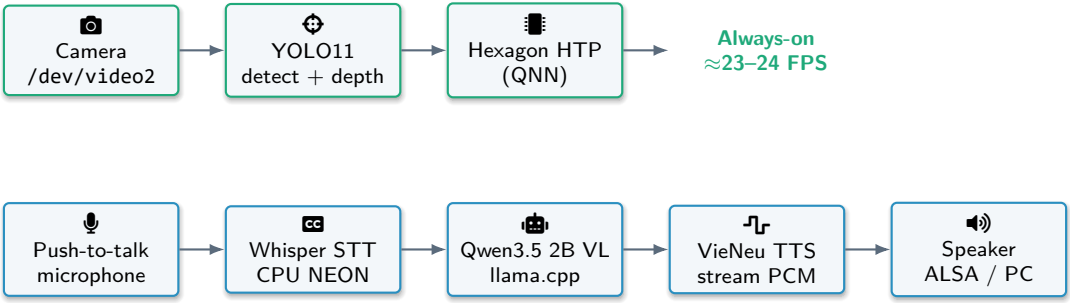
Pipeline đầu-cuối



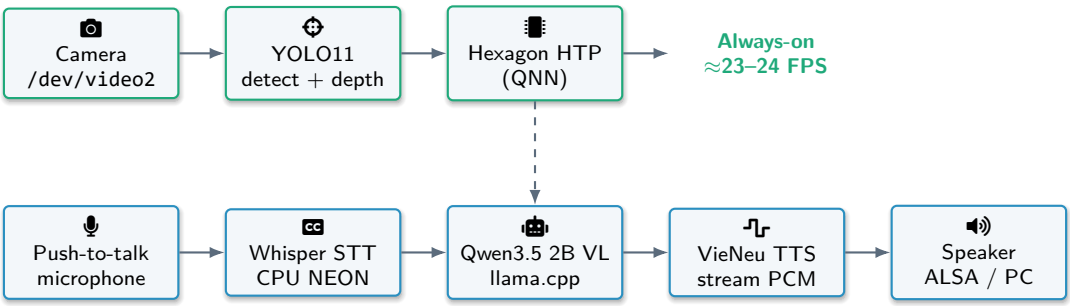
Pipeline đầu-cuối



Pipeline đầu-cuối



Pipeline đầu-cuối



Mũi tên nét đứt: scene facts (vật thể, khoảng cách, nguy hiểm) từ detector/depth được nạp trực tiếp vào prompt của VLM ở *mọi* lượt hỏi – câu trả lời luôn bám theo những gì camera đang thấy *ngay lúc đó*.

Nền tảng phần cứng

Thành phần	Chi tiết
Dev board	Qualcomm QCS8550 Kalama HDK
OS trên box	`kalama-qti-distro-ubuntu-fullstack-debug`
NPU	Hexagon HTP, 4 vùng cảm biến nhiệt (`nspss-0..3`)
GPU	Adreno 740 (nhận diện qua OpenCL, chưa dùng ở bản chạy chính)
CPU	Kryo, tập lệnh SIMD ARM NEON
Kết nối host	USB (ADB), VID `05C6` / PID `901D`

Vì sao quan trọng

NPU là tài nguyên **chia sẻ**: vòng lặp nhận thức luôn chạy và VLM theo yêu cầu cùng cạnh tranh chung một cụm engine Hexagon HTP.

Perception không bao giờ nhường quyền

- YOLO11 detector + depth đơn mắt chạy liên tục trên Hexagon HTP qua QNN.
- Đo thực tế trên box: **23,4–23,7 FPS** throughput ổn định của detector.
- Độ tươi của khung hình được theo dõi rõ ràng (`frame_age_ms`) – trạng thái cũ/mới được quan sát được, không phải giả định.
- **Nguyên tắc thiết kế:** perception luôn giữ độ ưu tiên cao nhất – lượt VLM phải chờ nó, chứ không phải ngược lại.

Telemetry đã verify (`GET /health`)

```
"scene": {"frame_id": 3644, "frame_age_ms": 9.5,
        "camera_ok": true, "depth_ok": true}
"resources": {"detector_fps": 23.40, "npu_temperature_c": 80.8}
```

STT: Ba hướng đã thử, một hướng lên bản chính

1. **GPU (Adreno 740, OpenCL)** – thiết bị nhận diện đúng, nhưng *cả hai* kernel OpenCL Q8 và FP16 của whisper.cpp đều segfault (`exit 139`). Loại bỏ: sẽ làm STT crash khi lên sản phẩm.

STT: Ba hướng đã thử, một hướng lên bản chính

1. **GPU (Adreno 740, OpenCL)** – thiết bị nhận diện đúng, nhưng *cả hai* kernel OpenCL Q8 và FP16 của whisper.cpp đều segfault (`exit 139`). Loại bỏ: sẽ làm STT crash khi lên sản phẩm.
2. **NPU (Hexagon HTP, QNN)** – hướng đúng về lâu dài; Whisper cần một QNN context được export qua Qualcomm AI Hub. Box hiện chưa có token/credential AI Hub $\Rightarrow$ bị chặn, chưa bị bỏ.

STT: Ba hướng đã thử, một hướng lên bản chính

1. **GPU (Adreno 740, OpenCL)** – thiết bị nhận diện đúng, nhưng *cả hai* kernel OpenCL Q8 và FP16 của whisper.cpp đều segfault (`exit 139`). Loại bỏ: sẽ làm STT crash khi lên sản phẩm.
2. **NPU (Hexagon HTP, QNN)** – hướng đúng về lâu dài; Whisper cần một QNN context được export qua Qualcomm AI Hub. Box hiện chưa có token/credential AI Hub $\Rightarrow$ bị chặn, chưa bị bỏ.
3. **Streaming thô** (`whisper-stream`, chunk 1,5 s) – tự sinh câu tiếng Việt giả khi phòng im lặng, mỗi chunk mã hóa mất $\approx$2,7 s. Không an toàn cho thiết bị hỗ trợ người khiếm thị. Loại bỏ.

STT: Ba hướng đã thử, một hướng lên bản chính

1. **GPU (Adreno 740, OpenCL)** – thiết bị nhận diện đúng, nhưng *cả hai* kernel OpenCL Q8 và FP16 của whisper.cpp đều segfault (`exit 139`). Loại bỏ: sẽ làm STT crash khi lên sản phẩm.
2. **NPU (Hexagon HTP, QNN)** – hướng đúng về lâu dài; Whisper cần một QNN context được export qua Qualcomm AI Hub. Box hiện chưa có token/credential AI Hub ⇒ bị chặn, chưa bị bỏ.
3. **Streaming thô** (`whisper-stream`, chunk 1,5 s) – tự sinh câu tiếng Việt giả khi phòng im lặng, mỗi chunk mã hóa mất ≈2,7 s. Không an toàn cho thiết bị hỗ trợ người khiếm thị. Loại bỏ.

Cấu hình đã lên bản chính

`whisper.cpp` trên CPU/NEON, **Base Q8** (nâng từ Small Q8), Silero VAD (ngưỡng 0,5, tối thiểu nói 250 ms, tối thiểu im lặng 400 ms), audio context chốt 512 frame, chỉ trả transcript *cuối cùng* sau khi thả nút (VAD-bounded final).

STT: Kết quả đo thực tế

Cấu hình	Audio	Thời gian xử lý	RTF
Small Q8 (bản cũ)	8,75 s	độ trễ cao hơn	–
Base Q8 + VAD ctx-512	8,75 s	**2,48 s**	**0,28**

RTF 0,28 nghĩa là một đoạn ghi âm mic thật dài 8,75 giây được nhận dạng chỉ trong khoảng 2,5 giây – nhanh hơn thời gian thực rõ rệt, chỉ dùng CPU, trong khi YOLO/depth vẫn chạy nguyên vẹn trên NPU.

VLM: Qwen3.5 2B VL

- Backend: `llama_cpp` (nhãn trên pipeline: *GenieX Qwen3.5 2B VL*).
- Chỉ được gọi *theo yêu cầu* – một lượt cho mỗi lần thả nút push-to-talk, không bao giờ chạy trong vòng lặp always-on.
- Prompt luôn được "bám thực tế" bằng scene facts sống từ detector/depth (loại vật thể, khoảng cách, nguy hiểm), không chỉ gửi khung hình thô.
- Việc được phép chạy (admission) bị chặn bởi cơ chế nhiệt NPU chia sẻ (xem phần sau).

TTS: VieNeu, phát streaming

- Backend `vieneu`, giọng **Phạm Tuyên**, tốc độ phát **1,5**×.
- **Streaming, không phải batch:** PCM theo từng cụm câu (`phrase_pcm`) ở 48 kHz – cụm âm đầu tiên bắt đầu phát trước khi toàn bộ câu trả lời tổng hợp xong.
- Hai đích phát độc lập: loa ALSA trên box, hoặc Web Audio API của trình duyệt để theo dõi từ xa khi phát triển.
- Cache kết quả quan sát trực tiếp: `cache_hits=4, cache_misses=0` với các cụm câu lặp lại.

Cơ chế chặn nhiệt (Thermal Admission Guard)

Quy tắc

Lượt VLM chỉ được **admit** khi `npu_temperature_c` $\leq 75.0°C$. Perception, STT, TTS **không** bị ràng buộc này.

Cơ chế chặn nhiệt (Thermal Admission Guard)

Quy tắc

Lượt VLM chỉ được **admit** khi `npu_temperature_c` $\leq 75.0°C$. Perception, STT, TTS **không** bị ràng buộc này.

Quan sát thực tế (hai lần kiểm tra độc lập, cùng một buổi):

```
"npu_temperature_c": 79.2 -> vlm_admitted: false
"npu_temperature_c": 80.8 -> vlm_admitted: false
"vlm_admission_reasons": ["npu_temperature_c=80.8 above 75.0"]
```

Cơ chế chặn nhiệt (Thermal Admission Guard)

Quy tắc

Lượt VLM chỉ được **admit** khi `npu_temperature_c` $\leq 75.0°C$. Perception, STT, TTS **không** bị ràng buộc này.

Quan sát thực tế (hai lần kiểm tra độc lập, cùng một buổi):

```
"npu_temperature_c": 79.2 -> vlm_admitted: false
"npu_temperature_c": 80.8 -> vlm_admitted: false
"vlm_admission_reasons": ["npu_temperature_c=80.8 above 75.0"]
```

Vì sao quan trọng với thiết bị hỗ trợ người khiếm thị: một lượt VLM "nói nhiều" không bao giờ được phép làm nghẽn hay crash vòng lặp phát hiện nguy hiểm. Khi box nóng, OmniGlass Edge *giảm cấp một cách an toàn* – câu hỏi xếp hàng chờ, còn detection vẫn chạy liên tục.

Demo trực tiếp – http://localhost:8090

Trên màn hình

- Camera MJPEG stream trực tiếp từ box
- Nút *giữ để nói* (hold-to-talk) cho hỏi-đáp rảnh tay
- Lab *chỉ test STT* độc lập (test mic, không gọi VLM/TTS)
- Bảng thời gian chi tiết từng lượt (STT, VLM first-token, chờ nhiệt, TTS)
- Scene facts thật đã gửi vào VLM (bằng chứng minh)

Telemetry trực tiếp (đã verify)


```
{
 "mode": "listening",
 "scene": {"camera_ok": true, "depth_ok": true},
 "components": {
   "stt": {"backend": "whisper_cli_cpu",
           "model_name": "ggml-base-q8_0.bin"},
   "tts": {"backend": "vieneu", "streaming": true
         },
   "vlm": {"backend": "llama_cpp", "admitted":
          false}
 },
 "resources": {"detector_fps": 23.40,
               "npu_temperature_c": 80.8}
}
```

Tổng hợp benchmark

Chỉ số	**Đo thực tế**
Throughput của detector	23,4 – 23,7 FPS
Độ tươi khung hình	$\approx$10 – 34 ms
Mô hình STT	Whisper Base, Q8 (trước là Small Q8)
RTF của STT (đoạn 8,75 s)	0,28 (2,48 s)
VAD	Silero, ngưỡng 0,5 / 250 ms / 400 ms
Sample rate / tốc độ phát TTS	48 kHz / 1,5$\times$
Ngưỡng nhiệt cho phép VLM	75,0 °C
Nhiệt NPU quan sát trong buổi test	79,2 – 80,8 °C
Backend STT trên GPU (Adreno 740)	Chưa sẵn sàng lên bản chính (segfault)

Những gì đã thay đổi trong buổi làm việc (git log)

`940e361` feat: stream verified Vietnamese TTS to PC

`9b19c45` feat: increase Vietnamese TTS speed to 1.5x

`cce8e50` feat: show live pipeline latency on demo

`307c48f` feat: add Vietnamese STT test lab

`b6385dc` **perf: accelerate Vietnamese STT on QCS8550**

`1935751` rebrand: rename demo UI to OmniGlass Edge

Branch `agent/edge-ai-v2-assistant`, đã push lên `github.com/technoob05/omniglass-vietnamese-edge-ai`. Bộ test toàn bộ profile: **12/12 pass**.

Hạn chế & hướng phát triển

- **Streaming ASR thật** cần một QNN context của Whisper export qua Qualcomm AI Hub (công bố của hãng: encoder Whisper-Tiny ≈18 ms trên NPU của QCS8550) – đang chặn ở credential AI Hub, không phải ở kiến trúc.
- Backend GPU (Adreno 740) OpenCL cho whisper.cpp vẫn còn segfault – chưa cô lập được root cause.
- Push-to-talk chỉ single-turn: chưa có barge-in / ngắt lời khi box đang nói.
- Chưa có đánh giá WER (word error rate) chính thức – kết quả hiện tại chỉ là độ trễ/throughput.
- Hiện chỉ tiếng Việt; đa ngôn ngữ là scope creep chưa nằm trong kế hoạch.

Điểm chính cần nhớ

- **OmniGlass Edge** chạy toàn bộ vòng lặp trợ giúp – phát hiện → hiểu → nói – hoàn toàn trên một box Qualcomm QCS8550, không cần round-trip qua cloud.
- Mọi con số trong bộ slide này đều được xác thực bằng một lần gọi `/health` thật hoặc một lượt test pass thật, không phải từ spec sheet.
- An toàn được đưa vào *kiến trúc*: perception luôn giữ ưu tiên, VLM bị chặn theo nhiệt, và một hướng streaming STT nhanh-nhưng-sai đã bị loại bỏ có chủ đích.

Demo: `http://localhost:8090`