OmniGlass Edge

Trợ lý đa phương thức Edge AI cho người khiếm thị – chạy hoàn toàn on-device trên Qualcomm QCS8550

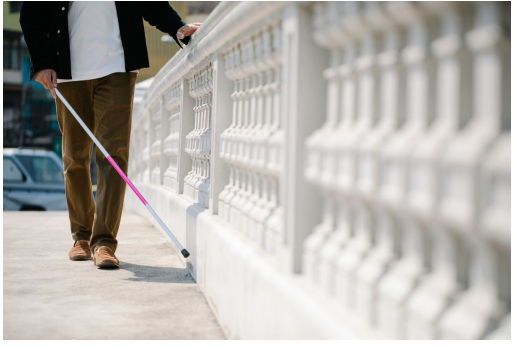
Nhóm 2

SoICT HUST Summer School 2026 – Trí tuệ nhân tạo tại biên (Edge AI)

Báo cáo Project, 10–14/08/2026



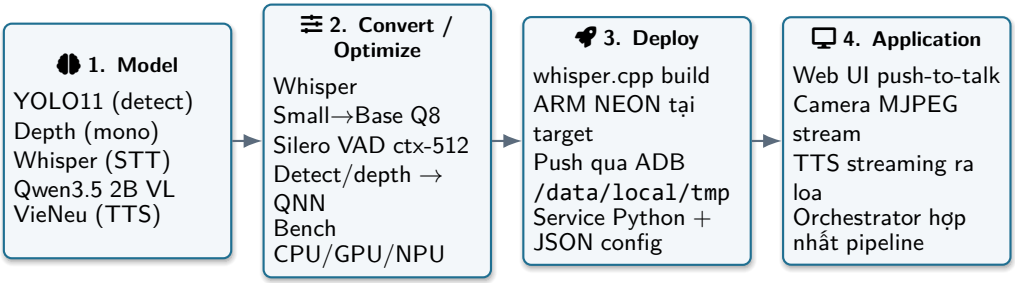
Động lực: vì sao phải là Edge, không phải Cloud?



Ảnh minh họa: người khiếm thị di chuyển bằng gậy dò đường (Pexels, free license).

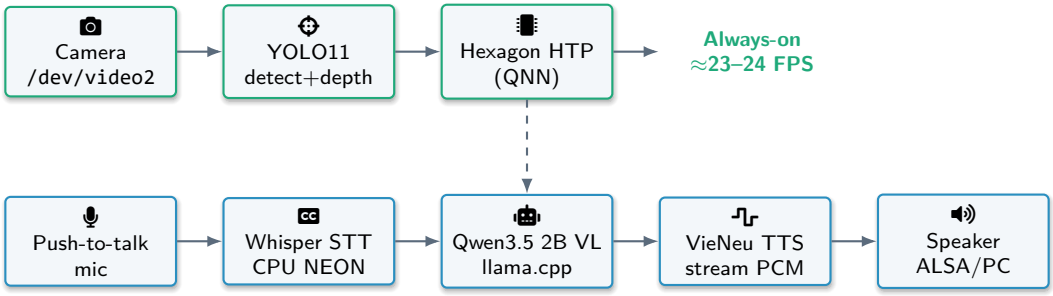
- Người khiếm thị cần **nhận biết môi trường** và **giao tiếp rảnh tay theo thời gian thực** – một trợ lý cảnh báo nguy hiểm không được phép trễ hay mất kết nối.
- **Cloud VLM**: round-trip 100s ms–vài giây, cần mạng liên tục, camera/mic phải rời khỏi thiết bị – rủi ro cho một use-case an toàn.
- **OmniGlass Edge**: detect + depth + STT + VLM + TTS chạy **cục bộ 100%** trên một board Qualcomm QCS8550 duy nhất – không phải demo model trên laptop rồi gọi là "edge".

Quy trình phát triển Edge AI: Model → Convert/Optimize → Deploy → App



Mỗi mũi tên là một quyết định kỹ thuật thật đã đưa ra và đo lại bằng benchmark trên chính board QCS8550 – không chỉ là sơ đồ lý thuyết.

Kiến trúc runtime trên thiết bị (đang chạy thật)




```
"scene": {"camera_ok": true, "depth_ok": true, "frame_age_ms": 9.5}
"resources": {"detector_fps": 23.40, "npu_temperature_c": 80.8}
```

Telemetry đọc trực tiếp từ `GET /health` trên box – không phải số liệu dựng.

Bài toán kỹ thuật khó nhất: đưa STT lên biên an toàn

Hướng thử	Kết quả	Quyết định
GPU Adreno 740 (OpenCL)	Cả Q8 và FP16 đều `segfault` (exit 139)	✗ Loại bỏ
NPU Hexagon HTP (QNN)	Cần QNN context export qua AI Hub – chưa có credential	◷ Tương lai
Streaming thô (1,5 s/chunk)	Tự sinh câu giả khi im lặng, mỗi chunk mất 2,7 s	✗ Loại bỏ
CPU NEON, Base Q8 + VAD	**8,75 s audio → 2,48 s (RTF 0,28)**	✓ Bản chính

Kết quả đo thực tế trên board

Detector **23,4–23,7 FPS** liên tục · STT RTF **0,28** · TTS streaming 48 kHz/1,5× · NPU admission gate tại **75°C** (quan sát thực tế 79–83°C).

Demo trực tiếp & an toàn: NPU chia sẻ, perception không bao giờ nhường

Demo trực tiếp – `http://localhost:8090`

- Camera stream thật + nút giữ-để-nói (push-to-talk)
- Bảng thời gian từng lượt: STT, VLM first-token, chờ nhiệt, TTS
- Có **video demo dự phòng** kèm hồ sơ nộp, phòng rủi ro khi trình diễn trực tiếp

Thermal Admission Guard

- VLM chỉ được chạy khi NPU $\leq 75°C$
- Perception (YOLO/depth) và STT/TTS **không** bị chặn – hazard detection không bao giờ đứng chờ VLM
- Khi box nóng: câu hỏi xếp hàng, camera vẫn cảnh báo nguy hiểm liên tục

Nộp sản phẩm & Kết luận

Yêu cầu nộp

- **Source code** – `github.com/technoob05/omniglass-vietnamese-edge-ai` (public)
- **Video demo** – quay trước buổi báo cáo, đính kèm cùng hồ sơ Drive
- **Slide trình bày** – tài liệu này

- Toàn bộ pipeline nhận thức + ngôn ngữ + giọng nói chạy **thật** trên board Qualcomm QCS8550, không phải mô phỏng.
- Mọi số liệu trong slide đều lấy từ `/health` thật hoặc test pass thật trên thiết bị.
- An toàn được thiết kế vào kiến trúc: một hướng streaming STT nhanh-nhưng-sai đã bị loại bỏ có chủ đích để bảo vệ vòng lặp cảnh báo nguy hiểm.

Cảm ơn – Q&A